

ANÁLISIS CALIDAD DEL AIRE EN BEIJING

La ciudad de Beijing ha enfrentado históricamente desafíos significativos respecto a la contaminación atmosférica, derivados de su rápida urbanización, actividad industrial y condiciones geográficas particulares. Durante el periodo comprendido entre 2013 y 2017, se implementaron diversas políticas de control ambiental, lo que convierte a este conjunto de datos en un escenario clave para entender la evolución de los contaminantes críticos.

Este estudio se centra en el análisis detallado de las partículas suspendidas PM2.5 y PM10, las cuales representan el mayor riesgo para la salud pública debido a su capacidad de penetración en el sistema respiratorio. A través de este análisis, buscamos transformar datos crudos en información estratégica para la toma de decisiones ambientales.

Objetivos

Para abordar esta problemática, nos hemos trazado los siguientes objetivos:

- **Diagnóstico Integral:** Evaluar el estado de la calidad del aire en las distintas estaciones de monitoreo para establecer una línea base de contaminación.
- **Identificación de Patrones:** Detectar las variables (temporales, climáticas o geográficas) que generan los picos de concentración de PM2.5 y PM10.
- **Simulaciones de Escenarios:** Desarrollar modelos que permitan simular el comportamiento de los contaminantes bajo condiciones específicas.
- **Formulación de Recomendaciones:** Proponer medidas mitigadoras y estrategias de control basadas en los hallazgos científicos del análisis.

A. Preparación de la información

Importación de Librerías y Exploración Inicial

En esta primera fase se importan las herramientas clave para el análisis de datos y la visualización (como pandas, numpy, matplotlib y seaborn).

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import folium
import os
import seaborn as sns
import statsmodels.api as sm
from pathlib import Path
```

```

ruta_base = Path('/Users/dannasarmientomartinez/Documents/Documentos - MacBook A
archivo_aotizhongxin = ruta_base / 'PRSA_Data_Aotizhongxin_20130301-20170228.csv

datos = pd.read_csv(archivo_aotizhongxin, na_values=["NA"])
print(datos.head())
print(datos.columns)
print(datos.info())

```

```

   No  year  month  day  hour  PM2.5  PM10  SO2  NO2   CO   O3  TEMP  \
0    1  2013     3    1     0    4.0   4.0   4.0   7.0  300.0  77.0  -0.7
1    2  2013     3    1     1    8.0   8.0   4.0   7.0  300.0  77.0  -1.1
2    3  2013     3    1     2    7.0   7.0   5.0  10.0  300.0  73.0  -1.1
3    4  2013     3    1     3    6.0   6.0  11.0  11.0  300.0  72.0  -1.4
4    5  2013     3    1     4    3.0   3.0  12.0  12.0  300.0  72.0  -2.0

```

```

   PRES  DEWP  RAIN  wd  WSPM  station
0  1023.0 -18.8   0.0 NNW   4.4 Aotizhongxin
1  1023.2 -18.2   0.0  N   4.7 Aotizhongxin
2  1023.5 -18.2   0.0 NNW   5.6 Aotizhongxin
3  1024.5 -19.4   0.0  NW   3.1 Aotizhongxin
4  1025.2 -19.5   0.0  N   2.0 Aotizhongxin
Index(['No', 'year', 'month', 'day', 'hour', 'PM2.5', 'PM10', 'SO2', 'NO2',
      'CO', 'O3', 'TEMP', 'PRES', 'DEWP', 'RAIN', 'wd', 'WSPM', 'station'],
      dtype='object')

```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 35064 entries, 0 to 35063
```

```
Data columns (total 18 columns):
```

```

#   Column  Non-Null Count  Dtype
---  -
0   No      35064 non-null    int64
1   year     35064 non-null    int64
2   month    35064 non-null    int64
3   day      35064 non-null    int64
4   hour     35064 non-null    int64
5   PM2.5    34139 non-null    float64
6   PM10     34346 non-null    float64
7   SO2      34129 non-null    float64
8   NO2      34041 non-null    float64
9   CO       33288 non-null    float64
10  O3       33345 non-null    float64
11  TEMP     35044 non-null    float64
12  PRES     35044 non-null    float64
13  DEWP     35044 non-null    float64
14  RAIN     35044 non-null    float64
15  wd       34983 non-null    object
16  WSPM     35050 non-null    float64
17  station  35064 non-null    object

```

```
dtypes: float64(11), int64(5), object(2)
```

```
memory usage: 4.8+ MB
```

```
None
```

```

In [2]: # Tratamiento de datos faltantes
datos = datos.sort_values(by=['station', 'year', 'month', 'day', 'hour'])

columnas_contaminantes = ['PM2.5', 'PM10', 'SO2', 'NO2', 'CO', 'O3', 'TEMP', 'PR

datos[columnas_contaminantes] = datos.groupby('station')[columnas_contaminantes]

```

```
datos[columnas_contaminantes] = datos.groupby('station')[columnas_contaminantes]
```

Carga y Unificación de Registros

En lugar de analizar los archivos por separado, utilizamos un bucle para leer los conjuntos de datos de las 12 estaciones de calidad del aire en Beijing y se concatenan todos en un único gran DataFrame (datos). Esto permite realizar un análisis global de toda la región.

```
In [3]: archivos = [
    "PRSA_Data_Aotizhongxin_20130301-20170228.csv",
    "PRSA_Data_Changping_20130301-20170228.csv",
    "PRSA_Data_Dingling_20130301-20170228.csv",
    "PRSA_Data_Dongsi_20130301-20170228.csv",
    "PRSA_Data_Guanyuan_20130301-20170228.csv",
    "PRSA_Data_Gucheng_20130301-20170228.csv",
    "PRSA_Data_Huairou_20130301-20170228.csv",
    "PRSA_Data_Nongzhanguan_20130301-20170228.csv",
    "PRSA_Data_Shunyi_20130301-20170228.csv",
    "PRSA_Data_Tiantan_20130301-20170228.csv",
    "PRSA_Data_Wanliu_20130301-20170228.csv",
    "PRSA_Data_Wanshouxigong_20130301-20170228.csv"
]

lista_dataframes = []

for archivo in archivos:
    ruta_archivo = ruta_base / archivo
    df = pd.read_csv(ruta_archivo, na_values=["NA"])
    lista_dataframes.append(df)

datos = pd.concat(lista_dataframes, ignore_index=True)

print(datos.head())
print(datos.shape)
print(datos["station"].unique())
```

	No	year	month	day	hour	PM2.5	PM10	SO2	NO2	CO	O3	TEMP	\
0	1	2013	3	1	0	4.0	4.0	4.0	7.0	300.0	77.0	-0.7	
1	2	2013	3	1	1	8.0	8.0	4.0	7.0	300.0	77.0	-1.1	
2	3	2013	3	1	2	7.0	7.0	5.0	10.0	300.0	73.0	-1.1	
3	4	2013	3	1	3	6.0	6.0	11.0	11.0	300.0	72.0	-1.4	
4	5	2013	3	1	4	3.0	3.0	12.0	12.0	300.0	72.0	-2.0	

	PRES	DEWP	RAIN	wd	WSPM	station
0	1023.0	-18.8	0.0	NNW	4.4	Aotizhongxin
1	1023.2	-18.2	0.0	N	4.7	Aotizhongxin
2	1023.5	-18.2	0.0	NNW	5.6	Aotizhongxin
3	1024.5	-19.4	0.0	NW	3.1	Aotizhongxin
4	1025.2	-19.5	0.0	N	2.0	Aotizhongxin

(420768, 18)

['Aotizhongxin' 'Changping' 'Dingling' 'Dongsi' 'Guanyuan' 'Gucheng'
'Huairou' 'Nongzhanguan' 'Shunyi' 'Tiantan' 'Wanliu' 'Wanshouxigong']

Preprocesamiento: Variables temporales y ordenamiento

Los datos originales tienen el tiempo dividido en columnas separadas (año, mes, día, hora). En este paso, se combinan en una sola columna de tipo fecha/hora (fecha), lo que facilita enormemente el filtrado y el análisis de series temporales. Después, la tabla se ordena lógicamente por estación y fecha.

```
In [4]: datos["fecha"] = pd.to_datetime(
        datos[["year", "month", "day", "hour"]]
    )

    print(datos[["year", "month", "day", "hour", "fecha"]].head())
    print(datos.dtypes)

    datos = datos.sort_values(["station", "fecha"]).reset_index(drop=True)

    print(datos[["station", "fecha"]].head())
    print(datos.shape)
```

	year	month	day	hour	fecha
0	2013	3	1	0	2013-03-01 00:00:00
1	2013	3	1	1	2013-03-01 01:00:00
2	2013	3	1	2	2013-03-01 02:00:00
3	2013	3	1	3	2013-03-01 03:00:00
4	2013	3	1	4	2013-03-01 04:00:00

```

No                int64
year              int64
month            int64
day              int64
hour            int64
PM2.5            float64
PM10             float64
SO2              float64
NO2              float64
CO               float64
O3               float64
TEMP             float64
PRES             float64
DEWP             float64
RAIN            float64
wd               object
WSPM            float64
station          object
fecha            datetime64[ns]
dtype: object
      station          fecha
0  Aotizhongxin 2013-03-01 00:00:00
1  Aotizhongxin 2013-03-01 01:00:00
2  Aotizhongxin 2013-03-01 02:00:00
3  Aotizhongxin 2013-03-01 03:00:00
4  Aotizhongxin 2013-03-01 04:00:00
(420768, 19)
```

B. Diagnóstico inicial

Promedio de Contaminación por Estación

Se ha realizado una consulta agrupando todos los registros históricos por estación para calcular el nivel promedio de los contaminantes más relevantes (PM2.5 y PM10). Los resultados se redondean y se ordenan de mayor a menor "avg_pm25" para identificar rápidamente cuáles son las zonas más afectadas.

```
In [5]: consulta_1 = (
    datos.groupby("station")[["PM2.5", "PM10"]]
        .mean()
        .round(2)
        .reset_index()
        .rename(columns={
            "PM2.5": "avg_pm25",
            "PM10": "avg_pm10"
        })
        .sort_values("avg_pm25", ascending=False)
    )

print(consulta_1)
```

	station	avg_pm25	avg_pm10
3	Dongsi	86.19	110.34
11	Wanshouxigong	85.02	112.22
7	Nongzhanguan	84.84	108.99
5	Gucheng	83.85	118.86
10	Wanliu	83.37	110.46
4	Guanyuan	82.93	109.02
0	Aotizhongxin	82.77	110.06
9	Tiantan	82.16	106.36
8	Shunyi	79.49	98.74
1	Changping	71.10	94.66
6	Huairou	69.63	91.48
2	Dingling	65.99	83.74

```
In [6]: consulta_1 = (
    datos.groupby("station")[["PM2.5", "PM10"]]
        .mean()
        .round(2)
        .reset_index()
        .rename(columns={
            "PM2.5": "avg_pm25",
            "PM10": "avg_pm10"
        })
        .sort_values("avg_pm25", ascending=False)
    )

print("Promedio de PM2.5 y PM10 por estación:")
print(consulta_1.to_string(index=False))
```

Promedio de PM2.5 y PM10 por estación:

station	avg_pm25	avg_pm10
Dongsi	86.19	110.34
Wanshouxigong	85.02	112.22
Nongzhanguan	84.84	108.99
Gucheng	83.85	118.86
Wanliu	83.37	110.46
Guanyuan	82.93	109.02
Aotizhongxin	82.77	110.06
Tiantan	82.16	106.36
Shunyi	79.49	98.74
Changping	71.10	94.66
Huairou	69.63	91.48
Dingling	65.99	83.74

```
In [7]: plt.figure(figsize=(12, 6))


# Asignamos el gráfico a 'ax'
ax = sns.barplot(data=consulta_1, x='avg_pm25', y='station', hue='station', palette='magma')

# ITERAMOS sobre cada contenedor para poner la etiqueta en todas las barras
for container in ax.containers:
    ax.bar_label(container, padding=3, fmt='%.2f')

plt.title('Promedio de PM2.5 por Estación (2013-2017)')
plt.xlabel('Concentración  $\mu\text{g}/\text{m}^3$ ')
plt.ylabel('Estación')

# Un pequeño margen extra a la derecha para que no se corten los números
plt.xlim(0, consulta_1['avg_pm25'].max() * 1.15)

plt.show()
```



El gráfico de barras muestra el promedio de concentración de partículas PM2.5 en las doce estaciones del estudio durante un periodo de cinco años.

- **Estaciones Críticas:** Dongsi, Wanshouxigong y Nongzhanguan presentan los niveles más altos, superando los 80 microgramos por metro cúbico
- **Estaciones con Menor Impacto:** Dingling registra la concentración más baja (aprox. 65 microgramos por metro cúbico), seguida de Huairou y Changping.

```
In [8]: plt.figure(figsize=(12, 6))


# 1. Asignamos a 'ax' y usamos la columna 'avg_pm10'
ax = sns.barplot(data=consulta_1, x='avg_pm10', y='station', hue='station', pale

# 2. El bucle mágico que recorre todos los contenedores de barras
for container in ax.containers:
    ax.bar_label(container, padding=3, fmt='%.2f')

plt.title('Promedio de PM10 por Estación (2013-2017)')
plt.xlabel('Concentración  $\mu\text{g}/\text{m}^3$ ')
plt.ylabel('Estación')

# 3. Ajustamos el límite del eje X para que los números respiren
plt.xlim(0, consulta_1['avg_pm10'].max() * 1.15)

plt.show()
```



Este gráfico muestra la distribución de partículas PM10 en las 12 estaciones de monitoreo. A diferencia del PM2.5, aquí se observa un cambio en el liderazgo de la contaminación:

- **Punto Máximo:** La estación Gucheng destaca significativamente, superando los 110 microgramos por metro cúbico y posicionándose como la zona con mayor presencia de partículas gruesas.
- **Zonas de Alta Concentración:** Wanshouxigong y Dongsi mantienen niveles elevados, cercanos a los 110 microgramos por metro cúbico.
- **Zonas con Mejor Calidad:** Dingling se mantiene como la estación más limpia con un promedio cercano a los 85 microgramos por metro cúbico, lo que representa una diferencia de casi el 40% respecto a Gucheng.

Observación: La tendencia general es superior a los niveles de PM2.5, lo cual es normal ya que el PM10 incluye partículas más grandes (polvo, polen, etc.).

A partir de 2013, Beijing implementó medidas críticas para reducir la contaminación. Este análisis diagnostica la evolución de PM2.5 y PM10 en 12 estaciones para ver la evolución de los niveles de estos contaminantes en los 5 años de medición.

```
In [9]: # Crear una tabla dinámica para PM2.5
tabla_pm25 = datos.pivot_table(values='PM2.5', index='year', columns='station',

# Crear una tabla dinámica para PM10
tabla_pm10 = datos.pivot_table(values='PM10', index='year', columns='station', a

# Mostrar la tabla de PM2.5
display(tabla_pm25)
```


station	Aotizhongxin	Changping	Dingling	Dongsi	Guanyuan	Gucheng	Huairou
year							
2013	82.392472	72.644508	64.754924	86.940286	82.129384	82.000832	68.67753
2014	90.796063	79.410815	74.155592	87.469606	88.382632	89.250122	77.30054
2015	82.118422	69.615911	64.610369	87.343090	82.411894	83.626937	70.65466
2016	74.104334	61.655940	59.827554	80.225952	77.136164	77.425347	61.12610
2017	94.762143	80.101284	68.365316	103.497114	93.070433	101.404301	74.26500

```
In [10]: fig, ax = plt.subplots(2, 1, figsize=(15, 12))

# Heatmap para PM2.5
sns.heatmap(tabla_pm25, annot=True, fmt=".1f", cmap="YlOrRd", ax=ax[0])
ax[0].set_title('Evolución Temporal de PM2.5 por Estación (Promedios Anuales)')

# Heatmap para PM10
sns.heatmap(tabla_pm10, annot=True, fmt=".1f", cmap="YlOrRd", ax=ax[1])
ax[1].set_title('Evolución Temporal de PM10 por Estación (Promedios Anuales)')

plt.tight_layout()
plt.show()
```



A pesar de las medidas implementadas desde 2013, el año 2017 muestra un repunte alarmante en casi todas las estaciones. En PM2.5, estaciones como Dongsi (103.5) y Wanshouxigong (107.3) alcanzaron sus niveles más altos del periodo, rompiendo la tendencia a la baja que se observaba en 2016.

C. Análisis de patrones

En esta sección, profundizamos en las variables dinámicas que condicionan la calidad del aire. No basta con saber cuánta contaminación hay; necesitamos entender qué factores facilitan su acumulación o su dispersión.

Analizaremos la influencia de los siguientes patrones sobre los niveles de PM2.5 y PM10:


- **Estacionalidad:** Evaluación de cómo los ciclos anuales (invierno vs. verano) y el uso de calefacción afectan las concentraciones.
- **Precipitaciones:** Análisis del "efecto lavado" de la lluvia y su capacidad para remover partículas en suspensión.
- **Dinámica del Viento:** Estudio de cómo la velocidad y dirección del aire actúan como mecanismo de ventilación o transporte de contaminantes hacia la ciudad.

El objetivo es identificar si los picos observados en el diagnóstico previo responden a eventos climáticos atípicos o a patrones estacionales predecibles.

Comportamiento del PM 2.5 durante el año(estacionalidad)

```
In [11]: # Preparar datos para el heatmap
datos['month'] = datos['fecha'].dt.month
datos['hour'] = datos['fecha'].dt.hour
pivot_table = datos.pivot_table(values='PM2.5', index='month', columns='hour', a

plt.figure(figsize=(12, 8))
sns.heatmap(pivot_table, cmap='YlOrRd', annot=False)
plt.title('Intensidad de PM2.5: Mes vs Hora (Promedio de todas las estaciones)')
plt.xlabel('Hora del día')
plt.ylabel('Mes del año')
plt.show()
```



El mapa de calor revela una estacionalidad agresiva y un patrón diario marcado:

- **Impacto Invernal:** Los meses de noviembre a febrero (11 a 2) muestran niveles críticos constantes (colores rojos intensos), probablemente debido a la calefacción de carbón y la inversión térmica.
- **Ciclo Diario:** Independientemente del mes, se observa un incremento de contaminación a partir de las 18:00 hasta la medianoche, coincidiendo con la hora pico de tráfico y el enfriamiento de la atmósfera que atrapa partículas a nivel del suelo.

- **Periodo de Alivio:** Los meses de verano (junio a agosto) presentan los niveles más bajos de PM2.5 en todas las franjas horarias."

Correlación y Dinámica Estacional de los Contaminantes


Para entender la raíz de los picos de contaminación, es necesario analizar la relación entre los diferentes agentes químicos y cómo estos fluctúan según la época del año.

A través de la matriz de correlación, identificamos que el PM2.5 no actúa de forma aislada. Presenta una dependencia crítica con:

- **Relación entre el PM2.5 y el PM10:** correlación casi perfecta. Confirma que ambas partículas comparten las mismas fuentes de emisión: carbón, polvo de construcción, tráfico. Gestionar uno implica gestionar el otro.
- **Fuentes de Combustión:** La fuerte correlación con CO (0.79) y NO2 (0.67) sugiere que las emisiones vehiculares e industriales son los motores principales de la contaminación.
- **Factores Meteorológicos:** La correlación negativa con la velocidad del viento (WSPM) confirma que la falta de ventilación atmosférica es el principal catalizador de los eventos críticos.

```
In [12]: cols_interes = ['PM2.5', 'PM10', 'SO2', 'NO2', 'CO', 'O3', 'TEMP', 'PRES', 'DEWP']
corr = datos[cols_interes].corr()

plt.figure(figsize=(10, 8))
sns.heatmap(corr, annot=True, fmt=".2f", cmap='coolwarm', center=0)
plt.title('Correlación: Contaminantes vs Variables Climáticas')
plt.show()
```



Al segmentar los datos por estaciones, observamos un patrón cíclico definido. La siguiente gráfica muestra cómo el invierno se consolida como el periodo más vulnerable, donde factores como la inversión térmica y el aumento en la demanda de calefacción disparan los niveles de todos los contaminantes de forma simultánea.

```
In [13]: def asignar_estacion(month):
    if month in [12, 1, 2]:
        return 'Invierno'
    elif month in [3, 4, 5]:
        return 'Primavera'
    elif month in [6, 7, 8]:
        return 'Verano'
    else:
        return 'Otoño'

    # Creamos la columna 'season' aplicando la función a la columna 'month'
    datos['season'] = datos['month'].apply(asignar_estacion)
    datos.head()
```

Out[13]:

	No	year	month	day	hour	PM2.5	PM10	SO2	NO2	CO	O3	TEMP	PRES
0	1	2013	3	1	0	4.0	4.0	4.0	7.0	300.0	77.0	-0.7	1023.0
1	2	2013	3	1	1	8.0	8.0	4.0	7.0	300.0	77.0	-1.1	1023.2
2	3	2013	3	1	2	7.0	7.0	5.0	10.0	300.0	73.0	-1.1	1023.5
3	4	2013	3	1	3	6.0	6.0	11.0	11.0	300.0	72.0	-1.4	1024.5
4	5	2013	3	1	4	3.0	3.0	12.0	12.0	300.0	72.0	-2.0	1025.2



```
In [16]: # 1. Agrupamos los datos por estación y calculamos el promedio de los 3 contaminantes
df_estaciones = datos.groupby('season')[['PM2.5', 'NO2', 'SO2']].mean().reindex(


plt.figure(figsize=(12, 6))
sns.set_style("whitegrid")

sns.lineplot(data=df_estaciones, x=df_estaciones.index, y='PM2.5', marker='o', label='PM2.5')
sns.lineplot(data=df_estaciones, x=df_estaciones.index, y='NO2', marker='o', label='NO2')
sns.lineplot(data=df_estaciones, x=df_estaciones.index, y='SO2', marker='o', label='SO2')

plt.title('Relación Estacional: PM2.5 vs SO2 y NO2', fontsize=15, pad=20)
plt.ylabel('Concentración Promedio (µg/m³)', fontsize=12)
plt.xlabel('Estación del Año', fontsize=12)
plt.legend(title='Contaminantes', frameon=False)
plt.ylim(0, 110) # Para que se parezca a tu escala de Excel

plt.show()
```

Relación Estacional: PM2.5 vs SO2 y NO2



- **Hallazgo:** El paralelismo entre las líneas de PM2.5 y NO2 a lo largo de las cuatro estaciones demuestra que las políticas de reducción deben ser integrales; cualquier medida que logre bajar el NO2 (control de tráfico, por ejemplo) tendrá un impacto directo y positivo en la reducción de las partículas PM2.5.

Efecto de las lluvias

```
In [21]: lluvia_ctx = datos[["station", "fecha", "RAIN", "PM10"]].copy()

# Ordenar por estación y fecha
lluvia_ctx = lluvia_ctx.sort_values(["station", "fecha"]).reset_index(drop=True)

# Antes
lluvia_ctx["pm10_before"] = lluvia_ctx.groupby("station")["PM10"].shift(1)

# Después
lluvia_ctx["pm10_after_1h"] = lluvia_ctx.groupby("station")["PM10"].shift(-1)
lluvia_ctx["pm10_after_3d"] = lluvia_ctx.groupby("station")["PM10"].shift(-72)
lluvia_ctx["pm10_after_5d"] = lluvia_ctx.groupby("station")["PM10"].shift(-120)
lluvia_ctx["pm10_after_7d"] = lluvia_ctx.groupby("station")["PM10"].shift(-168)

# Filtrar registros con PM10 válido y lluvia
lluvia_eventos = lluvia_ctx[
    (lluvia_ctx["PM10"].notna()) & (lluvia_ctx["RAIN"] > 0)
].copy()

consulta_lluvia = (
    lluvia_eventos.groupby("station")
    .agg(
        pm10_before_rain=("pm10_before", "mean"),
        pm10_during_rain=("PM10", "mean"),
        pm10_after_1h=("pm10_after_1h", "mean"),
        pm10_after_3d=("pm10_after_3d", "mean"),
        pm10_after_5d=("pm10_after_5d", "mean"),
        pm10_after_7d=("pm10_after_7d", "mean")
    )
)
```

```

        .round(2)
        .reset_index()
        .sort_values("station")
    )

print(consulta_lluvia.to_string(index=False))

```

station	pm10_before_rain	pm10_during_rain	pm10_after_1h	pm10_after_3d
pm10_after_5d	pm10_after_7d			
Aotizhongxin	79.40	72.63	64.07	87.57
102.70	111.13			
Changping	71.63	65.58	57.05	70.63
77.79	87.32			
Dingling	63.48	57.44	49.72	60.13
68.17	78.95			
Dongsi	77.97	72.55	64.77	88.29
103.81	109.01			
Guanyuan	79.99	73.81	66.37	87.17
100.64	109.34			
Gucheng	81.81	74.47	63.69	96.77
112.15	122.43			
Huairou	75.53	69.50	62.31	71.56
81.86	92.95			
Nongzhanguan	75.05	69.24	60.66	83.99
98.99	107.22			
Shunyi	72.75	67.65	60.86	75.60
90.16	97.33			
Tiantan	78.37	72.50	64.18	83.79
96.49	104.29			
Wanliu	75.05	70.30	62.60	85.41
99.54	106.07			
Wanshouxigong	79.37	73.57	66.36	85.13
102.40	111.15			


El análisis revela que la precipitación actúa como un filtro natural crítico para la calidad del aire. Al estudiar los niveles de PM10 antes, durante y después de eventos de lluvia, se observa una reducción inmediata en la concentración de partículas. El punto de mayor limpieza ocurre apenas una hora después de cesar la lluvia, logrando reducir el promedio de contaminación de 78 microgramos por metro cúbico a 62 microgramos por metro cúbico, más o menos. Sin embargo, este efecto es temporal; los datos muestran que tras 7 días, la concentración tiende a rebotar por encima de los niveles iniciales, lo que sugiere una acumulación progresiva de contaminantes en ausencia de nuevas lluvias.

```

In [22]: # Tomamos el promedio general de todas las estaciones para ver la tendencia
rain_trend = consulta_lluvia.mean(numeric_only=True)
etapas = ['Antes', 'Durante', '1h Después', '3d Después', '5d Después', '7d Desp

plt.figure(figsize=(10, 5))
plt.plot(etapas, rain_trend.values, marker='o', linestyle='-', color='blue', lin
plt.fill_between(etapas, rain_trend.values, alpha=0.1, color='blue')
plt.title('Impacto de la Lluvia en la concentración de PM10')
plt.ylabel('µg/m³ de PM10')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()

```



Hallazgos:

- **Reducción Inmediata:** La lluvia logra un 'lavado' del aire que disminuye las partículas PM10 de manera significativa durante el evento.
- **Ventana de Aire Limpio:** El aire alcanza su máxima pureza aproximadamente 1 hora después de la lluvia.
- **Resiliencia del Contaminante:** El beneficio de la lluvia es volátil. A partir del tercer día, la contaminación recupera sus niveles previos, alcanzando su punto máximo al séptimo día de sequía.

Tras identificar los patrones estacionales y meteorológicos clave, el siguiente paso fundamental es cuantificar cómo interactúan estas variables para determinar la concentración final de PM2.5. Para lograrlo, hemos desarrollado un modelo de regresión lineal múltiple (Mínimos Cuadrados Ordinarios, OLS) que actúa como el "cerebro" estadístico de nuestro simulador.

```
In [24]: # 1. Definimos las columnas que vamos a usar
features = ['WSPM', 'TEMP', 'NO2', 'CO', 'SO2', 'RAIN']
objetivo = 'PM2.5'

# 2. Creamos un nuevo dataframe que solo contenga esas columnas y eliminamos fil
datos_limpios = datos[features + [objetivo]].dropna()

# 3. Opcional: Eliminar valores infinitos (por si acaso)
datos_limpios = datos_limpios.replace([np.inf, -np.inf], np.nan).dropna()

# 4. Ahora sí, preparamos las variables para el modelo
X = datos_limpios[features]
y = datos_limpios[objetivo]
X = sm.add_constant(X)

# 5. Entrenamos
modelo_stats = sm.OLS(y, X).fit()
print(modelo_stats.summary())
```

OLS Regression Results

=====						
Dep. Variable:	PM2.5	R-squared:	0.675			
Model:	OLS	Adj. R-squared:	0.675			
Method:	Least Squares	F-statistic:	1.345e+05			
Date:	Sun, 15 Mar 2026	Prob (F-statistic):	0.00			
Time:	20:05:33	Log-Likelihood:	-2.0392e+06			
No. Observations:	388816	AIC:	4.078e+06			
Df Residuals:	388809	BIC:	4.079e+06			
Df Model:	6					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-23.7467	0.248	-95.587	0.000	-24.234	-23.260
WSPM	0.8159	0.065	12.466	0.000	0.688	0.944
TEMP	1.1837	0.007	170.054	0.000	1.170	1.197
NO2	0.5143	0.003	161.841	0.000	0.508	0.521
CO	0.0448	9.48e-05	472.736	0.000	0.045	0.045
SO2	0.3009	0.004	70.870	0.000	0.293	0.309
RAIN	-0.0068	0.090	-0.076	0.939	-0.183	0.169
=====						
Omnibus:	136436.528	Durbin-Watson:	0.190			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	2199100.915			
Skew:	1.259	Prob(JB):	0.00			
Kurtosis:	14.376	Cond. No.	5.83e+03			
=====						

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 5.83e+03. This might indicate that there are strong multicollinearity or other numerical problems.

Los resultados obtenidos del modelo de regresión lineal nos permiten extraer conclusiones críticas para el diseño de políticas públicas y estrategias de mitigación.

- El modelo presenta un coeficiente de determinación (R-squared) de 0.675. Esto significa que las seis variables seleccionadas logran explicar el 67.5% de toda la variación observada en los niveles de PM2.5 en Beijing.
- Los resultados validan estadísticamente que los contaminantes derivados de la combustión son los motores principales del PM2.5. Todos presentan coeficientes positivos y p-values de 0.000, confirmando una relación causa-efecto inequívoca.
- El modelo confirma de forma definitiva lo que sugería el análisis de correlación estacional. La lluvia tiene un coeficiente insignificante (-0.0068) y, fundamentalmente, un p-value de 0.939. Esto significa que el efecto de la lluvia es estadísticamente nulo y debe considerarse simplemente "ruido" en el sistema.

D. Medidas para la reducción de la contaminación en Beijing y sus posibles KPIs de éxito

Medida 1: Reducción del 10% del tráfico entre las 9:00 y las 11:00

En esta simulación se evalúa un escenario hipotético de política urbana: reducir un 10% la intensidad del tráfico privado durante la franja de 9:00 a 11:00 de la mañana.

Como el dataset no incluye una variable directa de tráfico, se utilizan **NO2** y **CO** como **proxies de emisiones asociadas a vehículos**, ya que ambos contaminantes suelen estar estrechamente relacionados con la actividad del tráfico urbano. La variable objetivo será **PM2.5**, al ser uno de los principales indicadores de contaminación atmosférica con impacto sobre la salud.

Para estimar el efecto de esta medida, se construye un modelo predictivo que relaciona la concentración de PM2.5 con variables atmosféricas y contaminantes observados, incluyendo temperatura, presión, velocidad del viento, lluvia, punto de rocío, hora del día y mes. Una vez ajustado el modelo, se modifica el escenario original reduciendo un 10% los valores de NO2 y CO únicamente en la franja horaria seleccionada, y se compara la predicción resultante con la situación observada.

Este enfoque no permite afirmar una relación causal exacta, pero sí proporciona una **estimación razonable del cambio esperado en PM2.5** bajo una política de reducción del tráfico en horas punta. Por tanto, el resultado debe interpretarse como una **simulación contrafactual basada en datos observacionales**, no como una prueba definitiva de causalidad.

```
In [26]: from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, r2_score

# Copia el dataframe principal para no modificar el original
df_model = df.copy()

# Nos quedamos con las variables que vamos a usar
cols = ['PM2.5', 'NO2', 'CO', 'TEMP', 'PRES', 'DEWP', 'RAIN', 'WSPM', 'hour', 'm
df_model = df_model[cols].copy()

# Eliminamos filas sin variable objetivo
df_model = df_model.dropna(subset=['PM2.5'])

df_model.head()

X = df_model.drop(columns='PM2.5')
y = df_model['PM2.5']

numeric_features = ['NO2', 'CO', 'TEMP', 'PRES', 'DEWP', 'RAIN', 'WSPM', 'hour',

numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='median'))
])
```

```

preprocessor = ColumnTransformer(transformers=[
    ('num', numeric_transformer, numeric_features)
])

model = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('regressor', LinearRegression())
])

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

model.fit(X_train, y_train)

y_pred = model.predict(X_test)

print("MAE:", round(mean_absolute_error(y_test, y_pred), 2))
print("R2:", round(r2_score(y_test, y_pred), 3))

# Creamos una copia del dataset original de entrada
X_sim = X.copy()

# Seleccionamos la franja horaria objetivo: 9, 10 y 11
mask_rush = X_sim['hour'].between(9, 11)

# Escenario contrafactual: reducimos NO2 y CO un 10%
X_sim.loc[mask_rush, 'NO2'] = X_sim.loc[mask_rush, 'NO2'] * 0.90
X_sim.loc[mask_rush, 'CO'] = X_sim.loc[mask_rush, 'CO'] * 0.90

# Predicción base y predicción simulada
pred_base = model.predict(X)
pred_sim = model.predict(X_sim)

# Guardamos resultados
results = df_model.copy()
results['PM25_pred_base'] = pred_base
results['PM25_pred_sim'] = pred_sim
results['delta_PM25'] = results['PM25_pred_sim'] - results['PM25_pred_base']

results.head()

impacto_franja = results.loc[mask_rush, 'delta_PM25']

print("Cambio medio estimado en PM2.5 entre 9:00 y 11:00:", round(impacto_franja
print("Cambio mediano estimado en PM2.5 entre 9:00 y 11:00:", round(impacto_franja
print("Reducción porcentual media estimada:",
    round(((results.loc[mask_rush, 'PM25_pred_base'] - results.loc[mask_rush,
    results.loc[mask_rush, 'PM25_pred_base'])).mean() * 100, 2), "%")

plot_df = results.loc[mask_rush].groupby('hour')[['PM25_pred_base', 'PM25_pred_s

plt.figure(figsize=(8,5))
plt.plot(plot_df.index, plot_df['PM25_pred_base'], marker='o', label='Escenario
plt.plot(plot_df.index, plot_df['PM25_pred_sim'], marker='o', label='Con reducci
plt.xlabel('Hora del día')
plt.ylabel('PM2.5 predicho medio')
plt.title('Impacto estimado de reducir un 10% el tráfico entre las 9:00 y las 11
plt.legend()

```


```
plt.grid(True, alpha=0.3)
plt.show()
```

MAE: 32.35

R2: 0.669

Cambio medio estimado en PM2.5 entre 9:00 y 11:00: -9.54 $\mu\text{g}/\text{m}^3$ Cambio mediano estimado en PM2.5 entre 9:00 y 11:00: -7.98 $\mu\text{g}/\text{m}^3$

Reducción porcentual media estimada: 12.19 %



Interpretación de la gráfica

La figura compara la concentración media predicha de **PM2.5** en dos escenarios: el escenario original y el escenario simulado con una reducción del **10%** en los indicadores asociados al tráfico entre las **9:00 y las 11:00**.

Se observa que la línea correspondiente al escenario simulado se sitúa sistemáticamente por debajo de la del escenario original en toda la franja analizada. Esta diferencia visual respalda la hipótesis de que una reducción del tráfico en horas punta podría contribuir de forma relevante a mejorar la calidad del aire.

Además, el descenso se mantiene en las tres horas analizadas, lo que sugiere que el efecto estimado no se concentra en un único momento puntual, sino que presenta cierta estabilidad dentro de la franja horaria estudiada. En consecuencia, la evidencia obtenida apunta a que las políticas de restricción del tráfico privado podrían tener un impacto positivo sobre la reducción de partículas finas en contextos urbanos con alta congestión.

Evaluación del modelo

Para estimar el impacto de una reducción del tráfico sobre la contaminación, se ajustó un modelo de regresión lineal para predecir los niveles de **PM2.5** a partir de variables meteorológicas y contaminantes asociados al tráfico, como **NO2** y **CO**.

El modelo obtuvo un **MAE de 32.35** y un **R² de 0.669**.

El **MAE (Mean Absolute Error)** indica el error medio absoluto de las predicciones. En este caso, el modelo comete un error promedio de **32.35 µg/m³** al estimar la concentración de PM2.5. Aunque este error no es pequeño en términos absolutos, debe interpretarse teniendo en cuenta la elevada variabilidad que suele presentar la contaminación atmosférica en entornos urbanos como Beijing.

Por su parte, el **R² de 0.669** indica que el modelo consigue explicar aproximadamente el **66.9% de la variabilidad observada** en los niveles de PM2.5. Este resultado puede considerarse razonablemente bueno para un análisis observacional de contaminación atmosférica, ya que sugiere que las variables incluidas capturan una parte importante de la dinámica del fenómeno.

En conjunto, estas métricas muestran que el modelo tiene una capacidad predictiva suficiente para emplearse como herramienta de simulación exploratoria. No obstante, los resultados deben interpretarse con cautela, ya que el modelo refleja asociaciones estadísticas y no relaciones causales estrictamente identificadas.

Una vez entrenado el modelo, se planteó un escenario contrafactual en el que los indicadores asociados al tráfico (**NO₂** y **CO**) se reducen un **10%** durante la franja horaria comprendida entre las **9:00 y las 11:00**. Esta medida pretende representar una política hipotética de restricción del tráfico privado en horas punta.

Los resultados muestran un **cambio medio estimado de -9.54 µg/m³ en PM2.5**, así como un **cambio mediano de -7.98 µg/m³**. Además, la **reducción porcentual media estimada es del 12.19%** respecto al escenario original.

Estos resultados sugieren que una reducción moderada del tráfico en esa franja horaria podría traducirse en una disminución apreciable de la contaminación por partículas finas. En términos prácticos, el modelo indica que actuar sobre la movilidad en horas punta tendría potencial para reducir la exposición de la población a niveles elevados de PM2.5.

No obstante, esta estimación debe interpretarse como una **simulación basada en proxies del tráfico**, no como una prueba causal definitiva. El dataset no contiene una medida directa de intensidad circulatoria, por lo que **NO₂** y **CO** se utilizan como aproximación a las emisiones vehiculares. Además, la contaminación urbana depende también de factores meteorológicos, estacionales y de otras fuentes emisoras, como la actividad industrial o la calefacción.

```
In [28]: # Franja horaria de hora punta
mask_peak = X['hour'].between(7, 10)

# Escenarios de reducción del tráfico
reducciones = [0.10, 0.20, 0.30]

# Predicción base
pred_base_2 = model.predict(X)

# Diccionario para guardar escenarios
escenarios = {}
```

```

for r in reducciones:
    X_tmp = X.copy()
    X_tmp.loc[mask_peak, 'NO2'] = X_tmp.loc[mask_peak, 'NO2'] * (1 - r)
    X_tmp.loc[mask_peak, 'CO'] = X_tmp.loc[mask_peak, 'CO'] * (1 - r)
    escenarios[r] = model.predict(X_tmp)

results_2 = df_model.copy()
results_2['PM25_pred_base'] = pred_base_2

for r in reducciones:
    results_2[f'PM25_pred_{int(r*100)}'] = escenarios[r]
    results_2[f'delta_{int(r*100)}'] = results_2[f'PM25_pred_{int(r*100)}'] - re

results_2.head()

for r in reducciones:
    col_pred = f'PM25_pred_{int(r*100)}'
    col_delta = f'delta_{int(r*100)}'

    cambio_medio = results_2.loc[mask_peak, col_delta].mean()
    reduccion_pct = (
        (results_2.loc[mask_peak, 'PM25_pred_base'] - results_2.loc[mask_peak, col_pred]) /
        results_2.loc[mask_peak, 'PM25_pred_base']
    ).mean() * 100

    print(f"Escenario {int(r*100)}%:")
    print(" Cambio medio estimado en PM2.5:", round(cambio_medio, 2), "µg/m3")
    print(" Reducción porcentual media estimada:", round(reduccion_pct, 2), "%")
    print()

plot_df_2 = results_2.loc[mask_peak].groupby('hour')[
    ['PM25_pred_base', 'PM25_pred_10', 'PM25_pred_20', 'PM25_pred_30']
].mean()

plt.figure(figsize=(9, 5))
plt.plot(plot_df_2.index, plot_df_2['PM25_pred_base'], marker='o', label='Escena
plt.plot(plot_df_2.index, plot_df_2['PM25_pred_10'], marker='o', label='Reduccion
plt.plot(plot_df_2.index, plot_df_2['PM25_pred_20'], marker='o', label='Reduccion
plt.plot(plot_df_2.index, plot_df_2['PM25_pred_30'], marker='o', label='Reduccion

plt.xlabel('Hora del día')
plt.ylabel('PM2.5 predicho medio')
plt.title('Impacto estimado de restricciones progresivas del tráfico en hora pun
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()

```

Escenario 10%:


Cambio medio estimado en PM2.5: -9.91 µg/m3
 Reducción porcentual media estimada: 13.05 %

Escenario 20%:

Cambio medio estimado en PM2.5: -19.81 µg/m3
 Reducción porcentual media estimada: 26.11 %

Escenario 30%:

Cambio medio estimado en PM2.5: -29.72 µg/m3
 Reducción porcentual media estimada: 39.16 %



Interpretación de la gráfica

La gráfica compara la concentración media predicha de **PM2.5** en cuatro escenarios: el escenario original y tres escenarios de restricción progresiva del tráfico privado, con reducciones del **10%**, **20%** y **30%** en los indicadores asociados al tráfico.

Si las curvas se separan de forma escalonada respecto al escenario original, ello indica que el efecto de la medida aumenta conforme la restricción del tráfico se vuelve más intensa. En este caso, los resultados muestran precisamente ese comportamiento: a medida que aumenta la reducción de **NO2** y **CO**, descienden también los niveles medios predichos de **PM2.5**.

Esta evidencia refuerza la idea de que limitar el tráfico privado durante las horas punta podría ser una herramienta eficaz para reducir la contaminación atmosférica en entornos urbanos densamente congestionados. Sin embargo, como en la medida anterior, los resultados deben interpretarse con cautela, ya que proceden de una simulación basada en relaciones estadísticas observadas y no de un experimento causal directo.

Medida 2: Restricción progresiva del tráfico privado en hora punta

En esta segunda simulación se plantea una política urbana más ambiciosa: aplicar una restricción progresiva del tráfico privado durante una franja de alta congestión, con el objetivo de evaluar cómo variaría la contaminación en función de la intensidad de la medida.

A diferencia del escenario anterior, en el que se analizaba una única reducción del 10%, en este caso se comparan **tres niveles de intervención** sobre los indicadores asociados al tráfico (**NO2** y **CO**): una reducción del **10%**, del **20%** y del **30%**. De este modo, es

posible estudiar si el efecto sobre la contaminación por **PM2.5** crece de forma proporcional o si aparecen diferencias más acusadas al aplicar restricciones más severas.

Dado que el dataset no incluye una variable directa de intensidad del tráfico, se utilizan **NO2** y **CO** como proxies de emisiones vehiculares. A partir del modelo previamente entrenado, se construyen varios escenarios contrafactuales modificando estas variables únicamente dentro de la franja horaria seleccionada, mientras que el resto de condiciones meteorológicas y temporales permanecen constantes.

Los resultados obtenidos muestran un patrón claramente escalonado. En el escenario de reducción del **10%**, el cambio medio estimado en PM2.5 es de **-9.91 $\mu\text{g}/\text{m}^3$** , lo que equivale a una reducción media del **13.05%** respecto al escenario original. Cuando la reducción del tráfico aumenta al **20%**, el descenso medio estimado alcanza los **-19.81 $\mu\text{g}/\text{m}^3$** , con una reducción porcentual del **26.11%**. Finalmente, en el escenario más restrictivo, con una disminución del **30%**, el modelo estima una caída media de **-29.72 $\mu\text{g}/\text{m}^3$** , equivalente al **39.16%**.

Estos resultados sugieren que existe una relación muy marcada entre la intensidad de la restricción del tráfico y la mejora esperada en la calidad del aire. En otras palabras, cuanto mayor es la reducción aplicada sobre los contaminantes asociados a la circulación de vehículos, mayor es también el descenso estimado en los niveles de PM2.5. Además, el comportamiento observado parece aproximadamente proporcional, lo que refuerza la hipótesis de que el tráfico urbano desempeña un papel relevante en la concentración de partículas finas durante las horas punta.

No obstante, esta estimación debe interpretarse como una **simulación observacional**, no como una prueba causal exacta. El análisis no mide directamente el volumen real de tráfico, sino que utiliza **NO2** y **CO** como aproximación a las emisiones vehiculares. Asimismo, la contaminación atmosférica depende también de factores meteorológicos, estacionales y de otras fuentes emisoras, como la actividad industrial, la calefacción o el polvo en suspensión.

En conjunto, la simulación indica que las políticas de restricción progresiva del tráfico privado podrían generar mejoras relevantes en la calidad del aire, especialmente si se aplican en franjas horarias de elevada congestión.

Medidas recomendadas para reducir la contaminación y su impacto en salud pública

A partir de los resultados obtenidos, la principal conclusión es que la reducción del tráfico privado en franjas horarias de elevada congestión podría constituir una herramienta eficaz para disminuir la contaminación por **PM2.5** y, con ello, reducir el riesgo sanitario asociado a la exposición prolongada a partículas finas.

Sin embargo, una medida de este tipo no debería plantearse como una prohibición aislada, sino como un **paquete coordinado de políticas públicas** orientadas a reducir la circulación de vehículos más contaminantes y a ofrecer alternativas reales de movilidad a la población.

En primer lugar, una de las medidas más razonables sería establecer **restricciones temporales de acceso al vehículo privado** en las horas de mayor congestión, especialmente en corredores urbanos con alta densidad de tráfico. Estas restricciones podrían aplicarse de forma gradual, comenzando por programas piloto en días laborables y evaluando su impacto antes de ampliar su alcance.

En segundo lugar, para que una política de este tipo sea socialmente viable, sería imprescindible acompañarla de un **refuerzo del transporte público**. Esto incluiría una mayor frecuencia de autobuses y metro en las franjas afectadas, carriles exclusivos para transporte colectivo y medidas que faciliten la intermodalidad. De este modo, la reducción del tráfico no se presentaría como una mera limitación, sino como una redistribución más eficiente de la movilidad urbana.

En tercer lugar, podrían implantarse mecanismos de **gestión de la demanda**, como peajes urbanos en horas punta, sistemas de acceso por matrícula, limitaciones a los vehículos más contaminantes o incentivos al uso compartido del coche. Estas políticas permitirían reducir progresivamente el volumen de tráfico sin necesidad de recurrir desde el inicio a una prohibición total.

Asimismo, sería recomendable impulsar medidas complementarias como la **flexibilización de horarios laborales**, el teletrabajo parcial y la escalonación de entradas y salidas en oficinas y centros educativos. Si parte de los desplazamientos se redistribuye fuera de las horas punta, la presión sobre la red viaria disminuiría y el efecto sobre la contaminación podría ser significativo.

Desde el punto de vista ambiental, este conjunto de medidas se justificaría porque la simulación realizada sugiere que una reducción del **10%** del tráfico en la franja analizada podría asociarse con una caída del **13.05%** en PM_{2.5}; una reducción del **20%**, con un descenso del **26.11%**; y una del **30%**, con una reducción del **39.16%**. Estos porcentajes indican que incluso intervenciones moderadas podrían traducirse en mejoras apreciables de la calidad del aire.

Desde el punto de vista sanitario, la relevancia de estas medidas es aún mayor. La exposición crónica a PM_{2.5} está asociada a un mayor riesgo de mortalidad prematura y a enfermedades cardiovasculares, respiratorias y oncológicas. Tomando como referencia una estimación reciente de **56,443 muertes prematuras atribuibles a PM_{2.5} en Beijing**, reducciones sostenidas de la contaminación del orden observado en esta simulación podrían representar, en términos aproximados, un beneficio potencial de gran magnitud en salud pública.

No obstante, estas cifras deben interpretarse con cautela. El presente análisis no permite afirmar con exactitud cuántas vidas se salvarían, ya que para ello sería necesaria una evaluación epidemiológica específica con datos de exposición anual, población afectada y funciones concentración-respuesta. Por tanto, el valor principal de esta propuesta no reside en fijar un número exacto de muertes evitadas, sino en mostrar que las políticas de reducción del tráfico pueden tener un impacto potencialmente muy importante tanto sobre la calidad del aire como sobre la salud de la población.

En consecuencia, la recomendación para la administración municipal sería adoptar una estrategia **gradual, focalizada y evaluable**: comenzar con restricciones piloto al tráfico en horas punta, reforzar simultáneamente el transporte público y monitorizar de forma continua la evolución de los niveles de contaminación y sus efectos sobre la salud urbana. De este modo, las decisiones políticas podrían basarse en evidencia acumulada y ajustarse progresivamente según los resultados observados.

Fuentes: [Springer — PM2.5 and health outcomes in Beijing · MDPI Toxics — PM2.5 exposure and mortality](#)

```
In [31]: # Definimos las franjas horarias a comparar
franjas = {
    '7-9': (7, 9),
    '9-11': (9, 11),
    '18-20': (18, 20)
}

reduccion = 0.10 # 10%

pred_base_franjas = model.predict(X)

resultados_franjas = []

for nombre, (h_ini, h_fin) in franjas.items():
    X_tmp = X.copy()

    mask = X_tmp['hour'].between(h_ini, h_fin)

    X_tmp.loc[mask, 'NO2'] = X_tmp.loc[mask, 'NO2'] * (1 - reduccion)
    X_tmp.loc[mask, 'CO'] = X_tmp.loc[mask, 'CO'] * (1 - reduccion)

    pred_sim = model.predict(X_tmp)

    delta = pred_sim - pred_base_franjas

    cambio_medio = delta[mask].mean()
    reduccion_pct = ((pred_base_franjas[mask] - pred_sim[mask]) / pred_base_franjas[mask]) * 100

    resultados_franjas.append({
        'franja': nombre,
        'cambio_medio_PM25': cambio_medio,
        'reduccion_pct_PM25': reduccion_pct
    })


df_franjas = pd.DataFrame(resultados_franjas)
df_franjas

df_franjas = df_franjas.sort_values(by='reduccion_pct_PM25', ascending=False)
print(df_franjas)

plt.figure(figsize=(8,5))
plt.bar(df_franjas['franja'], df_franjas['reduccion_pct_PM25'])
plt.xlabel('Franja horaria')
plt.ylabel('Reducción porcentual media estimada de PM2.5')
plt.title('Comparación del impacto estimado de reducir un 10% el tráfico según 1')
plt.grid(axis='y', alpha=0.3)
plt.show()
```

	franja	cambio_medio_PM25	reduccion_pct_PM25
2	18-20	-9.343820	14.359712
0	7-9	-10.031655	13.567103
1	9-11	-9.543414	12.191532

Comparación del impacto estimado de reducir un 10% el tráfico según la franja horaria



Comparación de franjas horarias de intervención y propuesta de medidas públicas

Con el fin de identificar en qué momento del día una política de restricción del tráfico podría resultar más eficaz, se compararon tres escenarios horarios de intervención: **7:00–9:00**, **9:00–11:00** y **18:00–20:00**. En todos los casos se aplicó la misma reducción del **10%** sobre los indicadores asociados al tráfico (**NO₂** y **CO**), utilizando como variable objetivo la concentración de **PM_{2.5}**.

Los resultados muestran que la franja de **18:00 a 20:00** presenta la **mayor reducción porcentual media estimada de PM_{2.5}**, con un descenso del **14.36%**. A continuación se sitúa la franja de **7:00 a 9:00**, con una reducción del **13.57%**, mientras que la franja de **9:00 a 11:00** registra una disminución del **12.19%**. En términos absolutos, la mayor caída media estimada en PM_{2.5} se observa entre **7:00 y 9:00** (**-10.03 µg/m³**), seguida por **9:00–11:00** (**-9.54 µg/m³**) y **18:00–20:00** (**-9.34 µg/m³**).

Estos resultados sugieren que el impacto ambiental de una reducción del tráfico no es uniforme a lo largo del día. Aunque las tres franjas producen mejoras apreciables, la comparación indica que las intervenciones aplicadas entre **18:00 y 20:00** podrían ofrecer el mayor rendimiento relativo en términos porcentuales, mientras que actuar entre **7:00 y 9:00** generaría la mayor reducción media absoluta de concentración. Por tanto, el análisis permite defender que la administración municipal no debería elegir una franja horaria de forma arbitraria, sino priorizar aquella en la que una reducción equivalente del tráfico genere el mayor beneficio estimado sobre la calidad del aire.

Desde el punto de vista de la política pública, estos resultados justifican la puesta en marcha de **medidas temporales y focalizadas de gestión de la movilidad** en las franjas identificadas como más prometedoras. En lugar de plantear una prohibición general del tráfico privado, una estrategia más realista consistiría en aplicar un **programa piloto escalonado** con varias herramientas complementarias.

En primer lugar, podría establecerse una **restricción temporal de acceso al vehículo privado** en los corredores con mayor congestión durante las franjas de **7:00–9:00** y **18:00–20:00**, que son las que muestran el mayor potencial de reducción de PM_{2.5}. Esta restricción podría implantarse de forma progresiva, empezando por vehículos más contaminantes o por determinadas zonas centrales.

En segundo lugar, sería necesario reforzar el **transporte público** en esas mismas franjas. Una política de limitación del tráfico solo tendría viabilidad social si se acompaña de una mayor frecuencia de metro y autobuses, carriles exclusivos, mejores conexiones intermodales y sistemas de aparcamiento disuasorio en la periferia. De este modo, la reducción del tráfico no se traduciría simplemente en una limitación, sino en una reorganización más eficiente de la movilidad urbana.

En tercer lugar, podrían aplicarse medidas de **gestión de la demanda**, como peajes urbanos en hora punta, acceso condicionado por matrícula, incentivos al coche compartido, promoción del teletrabajo parcial y escalonación de horarios laborales. Estas medidas permitirían repartir mejor los desplazamientos a lo largo del día y reducir la concentración de emisiones en los momentos más críticos.

La relevancia sanitaria de estas propuestas es elevada, ya que la **PM_{2.5}** es uno de los contaminantes atmosféricos más perjudiciales para la salud. La Organización Mundial de la Salud señala que la contaminación del aire ambiente está asociada a enfermedad cardiovascular, ictus, EPOC, infecciones respiratorias y cáncer de pulmón, y la considera una causa importante de mortalidad prematura. :contentReference[oaicite:1]{index=1}

Tomando como referencia un estudio reciente que estimó **56.443 muertes prematuras atribuibles a la exposición de largo plazo a PM_{2.5} en Beijing**, puede hacerse una aproximación ilustrativa del potencial impacto en salud pública. Si una reducción de la contaminación similar a la estimada en este análisis se sostuviera de forma amplia y continuada, una caída del **14.36%** en PM_{2.5} equivaldría, en términos puramente aproximados, a unas **8.106 muertes prematuras evitables al año**; una reducción del **13.57%** equivaldría a unas **7.660**; y una del **12.19%**, a unas **6.880**. Estas cifras se obtienen aplicando directamente los porcentajes estimados a la referencia de 56.443 muertes atribuibles y deben entenderse únicamente como una **aproximación de orden de magnitud**, no como una predicción exacta. :contentReference[oaicite:2]{index=2}

Por tanto, la propuesta al ayuntamiento de Beijing podría formularse de la siguiente manera: **priorizar programas piloto de reducción del tráfico en las franjas de 7:00–9:00 y 18:00–20:00**, reforzando simultáneamente el transporte público y monitorizando de forma continua la calidad del aire. La franja de **18:00–20:00** aparece como la mejor candidata si el criterio principal es la **reducción porcentual relativa**, mientras que la franja de **7:00–9:00** sería preferible si se prioriza la **reducción absoluta media de**

PM2.5. En ambos casos, la recomendación se justifica porque el modelo estima que actuar sobre la movilidad en estos periodos podría generar mejoras relevantes en la calidad del aire y, potencialmente, beneficios sanitarios importantes a largo plazo.

No obstante, conviene subrayar una limitación esencial: este trabajo no demuestra cuántas vidas se salvarían realmente con una restricción horaria concreta, ya que para ello sería necesario realizar una evaluación epidemiológica específica con datos de exposición anual, población afectada, mortalidad base y funciones concentración-respuesta. En consecuencia, el valor principal de estas cifras no reside en fijar un número exacto de muertes evitadas, sino en mostrar que incluso reducciones moderadas del tráfico en horas punta podrían tener un impacto potencialmente muy relevante sobre la salud pública.

Recomendación final

A la luz de los resultados, se recomienda al ayuntamiento de Beijing considerar políticas de restricción temporal del tráfico privado en franjas de alta congestión como herramienta de salud pública. La evidencia obtenida sugiere que intervenir entre **18:00 y 20:00** podría maximizar la reducción porcentual relativa de PM2.5, mientras que actuar entre **7:00 y 9:00** podría producir la mayor caída absoluta media del contaminante. En ambos casos, la medida debería implantarse de forma gradual, acompañada de refuerzo del transporte público y de una evaluación continua de sus efectos ambientales y sanitarios.

```
In [32]: # Umbral de viento bajo: percentil 25
umbral_viento_bajo = X['WSPM'].quantile(0.25)

# Episodios meteorológicos desfavorables:
# poco viento + ausencia de lluvia
mask_meteo = (X['WSPM'] <= umbral_viento_bajo) & (X['RAIN'] == 0)

print("Umbral de viento bajo:", round(umbral_viento_bajo, 2))
print("Número de observaciones en episodios desfavorables:", mask_meteo.sum())

# Predicción base
pred_base_meteo = model.predict(X)

# Copia para simulación
X_meteo = X.copy()

# Reducción del 10% en NO2 y CO durante episodios desfavorables
X_meteo.loc[mask_meteo, 'NO2'] = X_meteo.loc[mask_meteo, 'NO2'] * 0.90
X_meteo.loc[mask_meteo, 'CO'] = X_meteo.loc[mask_meteo, 'CO'] * 0.90

# Nueva predicción
pred_sim_meteo = model.predict(X_meteo)

results_meteo = df_model.copy()
results_meteo['PM25_pred_base'] = pred_base_meteo
results_meteo['PM25_pred_sim'] = pred_sim_meteo
results_meteo['delta_PM25'] = results_meteo['PM25_pred_sim'] - results_meteo['PM

impacto_meteo = results_meteo.loc[mask_meteo, 'delta_PM25']
```

```

print("Cambio medio estimado en PM2.5 en episodios desfavorables:", round(impact
print("Cambio mediano estimado en PM2.5 en episodios desfavorables:", round(impa
print("Reducción porcentual media estimada:",
      round(((results_meteo.loc[mask_meteo, 'PM25_pred_base'] - results_meteo.loc
              results_meteo.loc[mask_meteo, 'PM25_pred_base'])).mean() * 100, 2),

plot_meteo = pd.DataFrame({
    'Escenario original': results_meteo.loc[mask_meteo, 'PM25_pred_base'],
    'Escenario con medida': results_meteo.loc[mask_meteo, 'PM25_pred_sim']
}).mean()

plt.figure(figsize=(7,5))
plt.bar(plot_meteo.index, plot_meteo.values)
plt.ylabel('PM2.5 predicho medio')
plt.title('Impacto estimado de reducir el tráfico en episodios de baja dispersió
plt.grid(axis='y', alpha=0.3)
plt.show()

```

Umbral de viento bajo: 0.9


Número de observaciones en episodios desfavorables: 8677

Cambio medio estimado en PM2.5 en episodios desfavorables: -12.97 µg/m³

Cambio mediano estimado en PM2.5 en episodios desfavorables: -10.79 µg/m³

Reducción porcentual media estimada: 12.69 %

Impacto estimado de reducir el tráfico en episodios de baja dispersión atmosférica



Medida 3: Protocolo de restricción temporal del tráfico en episodios de baja dispersión atmosférica

Además de la intensidad del tráfico, la contaminación atmosférica urbana depende de forma importante de las condiciones meteorológicas. En particular, la combinación de **baja velocidad del viento** y **ausencia de lluvia** favorece la acumulación de contaminantes en las capas bajas de la atmósfera, dificultando su dispersión y

aumentando el riesgo de episodios de mala calidad del aire. La evidencia sanitaria disponible muestra que la exposición a **PM_{2.5}** está asociada a un mayor riesgo de enfermedad cardiovascular, ictus, EPOC, infecciones respiratorias y cáncer de pulmón, por lo que actuar sobre estos episodios tiene una clara justificación de salud pública.

Con el fin de identificar estas situaciones de mayor vulnerabilidad atmosférica, se definieron como **episodios desfavorables** aquellos periodos en los que la velocidad del viento se situaba por debajo del percentil 25 de la muestra, es decir, por debajo de **0.9 m/s**, y en los que además no se registraba precipitación. Bajo este criterio se identificaron **8.677 observaciones** con condiciones meteorológicas propicias para la acumulación de contaminación.

A continuación, se simuló una política de reducción del tráfico durante esos episodios, aplicando una disminución del **10%** en los indicadores asociados a las emisiones vehiculares (**NO₂** y **CO**). Los resultados muestran un **cambio medio estimado de -12.97 µg/m³ en PM_{2.5}**, un **cambio mediano de -10.79 µg/m³** y una **reducción porcentual media del 12.69%**.

Estos resultados sugieren que, cuando la ciudad entra en una situación de baja dispersión atmosférica, una reducción moderada del tráfico podría generar una mejora apreciable en la calidad del aire. Desde el punto de vista de la política pública, esta conclusión es especialmente relevante porque permite defender una estrategia **selectiva y preventiva**: no sería necesario restringir la movilidad de forma constante, sino únicamente en aquellos momentos en los que las condiciones meteorológicas aumentan la probabilidad de acumulación de partículas finas.

A la luz de estos resultados, se propone al ayuntamiento de Beijing implantar un **protocolo municipal de episodios de baja dispersión atmosférica**, activado automáticamente cuando se detecten condiciones combinadas de **viento muy débil** y **ausencia de lluvia**.

La medida principal consistiría en una **restricción temporal del tráfico privado más contaminante** durante estos episodios, priorizando las zonas urbanas con mayor densidad circulatoria. Esta restricción podría aplicarse inicialmente mediante un programa piloto, centrado en accesos al centro urbano, corredores especialmente congestionados y días laborables con previsión meteorológica adversa.

Para que la medida sea viable socialmente, debería ir acompañada de un **refuerzo extraordinario del transporte público** en los periodos de activación del protocolo, aumentando la frecuencia de metro y autobuses, habilitando carriles prioritarios y facilitando aparcamientos disuasorios en la periferia. De este modo, la política no se presentaría como una mera prohibición, sino como una estrategia de movilidad alternativa para proteger la salud de la población.

Asimismo, el protocolo podría incorporar medidas complementarias como:

- recomendación de **teletrabajo parcial** en días de alerta;
- **escalonación horaria** en oficinas y centros educativos;

- limitación temporal de actividades que generen polvo o emisiones adicionales;
- campañas informativas dirigidas a la población vulnerable, especialmente personas mayores, niños y pacientes con enfermedades respiratorias o cardiovasculares.

Cuando la meteorología dificulta la dispersión de contaminantes, pequeñas reducciones del tráfico pueden generar mejoras significativas en la calidad del aire y, potencialmente, beneficios sanitarios relevantes a largo plazo.

Por ello, se recomienda implantar un **programa piloto de restricciones temporales del tráfico en episodios de baja dispersión atmosférica**, acompañado de refuerzo del transporte público, monitorización continua de la calidad del aire y evaluación posterior de resultados. Esta estrategia permitiría actuar en los momentos de mayor riesgo, maximizar la eficacia ambiental de la medida y reducir el coste social de aplicar restricciones de forma indiscriminada.

Nota metodológica sobre la estimación de vidas potencialmente evitables

Las cifras de “vidas potencialmente salvadas” presentadas en este trabajo deben interpretarse con cautela. No representan una predicción exacta del número de muertes evitadas, sino una **aproximación ilustrativa** obtenida al aplicar los porcentajes estimados de reducción de **PM2.5** a una cifra de referencia de mortalidad atribuible en Beijing.

Por ello, estas estimaciones **no son directamente comparables ni sumables entre sí**. Cada medida analizada responde a un escenario diferente: algunas se aplican en franjas horarias concretas, otras comparan distintos niveles de intensidad de la restricción del tráfico y otras se activan únicamente bajo condiciones meteorológicas desfavorables. En consecuencia, aunque todas producen una reducción estimada de PM2.5, no implican necesariamente una disminución equivalente de la exposición anual media de toda la población.

Además, varias de las medidas podrían solaparse en la práctica. Por ejemplo, una restricción del tráfico en una franja horaria determinada y un protocolo activado en episodios de baja dispersión atmosférica podrían afectar a parte de los mismos periodos. Esto significa que sus impactos en salud no deben sumarse como si fueran independientes.

Desde un punto de vista metodológico, el valor principal de estas cifras no reside en fijar un número exacto de muertes evitadas, sino en ofrecer un **orden de magnitud** del posible beneficio sanitario asociado a una reducción sostenida de la contaminación. Para estimar con rigor cuántas vidas podrían salvarse realmente sería necesario realizar una **evaluación de impacto en salud** completa, incorporando funciones concentración-respuesta, datos demográficos detallados, mortalidad base por causas específicas y una estimación precisa del efecto de cada medida sobre la exposición media anual.

En consecuencia, la interpretación adecuada es la siguiente: las medidas con mayor reducción estimada de PM2.5 son también las que presentan un mayor **potencial** de

beneficio sanitario, pero las cifras de vidas evitables deben entenderse como aproximaciones orientativas y no como resultados exactos.

Tabla ejecutiva de medidas propuestas para el Ayuntamiento de Beijing

Medida	Tipo	Coste estimado	Viabilidad	Resultado estimado sobre PM2.5	Impacto sanitario potencial*
1. Restricción piloto del tráfico entre 9:00 y 11:00	Restictiva focalizada	Medio: señalización, control, comunicación pública y refuerzo puntual del transporte público	Alta como programa piloto	Reducción media estimada de -9.54 $\mu\text{g}/\text{m}^3$ y caída porcentual del 12.19%	Aproximadamente 6.880 muertes prematuras evitables/año si una reducción similar de PM2.5 se mantuviera de forma amplia y continuada
2. Restricción progresiva del tráfico en hora punta	Restictiva escalonada	Medio-alto: más control, más capacidad operativa y mayor refuerzo del transporte público	Media	10% tráfico: 13.05% menos PM2.5; 20% tráfico: 26.11% menos; 30% tráfico: 39.16% menos	Aproximadamente 7.366, 14.737 y 22.103 muertes potencialmente evitables/año, respectivamente, bajo el supuesto de sostenimiento amplio del efecto
3. Priorización por franjas horarias	Gestión inteligente de movilidad	Medio	Alta	18:00–20:00: mejor reducción relativa (14.36%); 7:00–9:00: mayor caída absoluta (-10.03 $\mu\text{g}/\text{m}^3$); 9:00–11:00: 12.19%	Aproximadamente 8.106 muertes potenciales evitables/año para 18:00–20:00 , 7.660 para 7:00–9:00 y 6.880 para 9:00–11:00
4. Protocolo de baja dispersión atmosférica	Restricción selectiva por meteorología	Medio	Alta	En episodios con WSPM < 0.9 m/s y RAIN = 0 , reducción media estimada de -12.97 $\mu\text{g}/\text{m}^3$ y caída del 12.69%	Aproximadamente 7.162 muertes prematuras evitables/año si el efecto fuera amplio y sostenido
5. App municipal de alertas y comunicación de riesgo	No restrictiva / reducción de exposición	Bajo: plataforma digital, alertas, integración de datos y	Muy alta	No reduce directamente las emisiones urbanas, pero puede reducir la exposición personal	Beneficio sanitario potencial por menor exposición aguda, especialmente en población vulnerable; no se

Medida	Tipo	Coste estimado	Viabilidad	Resultado estimado sobre PM2.5	Impacto sanitario potencial*
		campana de comunicación		durante picos de contaminación	estima aquí en vidas salvadas directas
6. Teletrabajo parcial y horarios escalonados	No restrictiva / fomento	Bajo-medio: incentivos, acuerdos con empresas, seguimiento y comunicación	Media-alta	Potencial para reducir desplazamientos pendulares y suavizar los picos de congestión; útil como complemento de las medidas horarias	No se estima aquí una cifra específica de vidas, pero puede reforzar la reducción de PM2.5 al disminuir emisiones de movilidad
7. Peaje urbano / control de acceso estructural	Restrictiva estructural	Alto: cámaras, sensores, sistemas de cobro, fiscalización e integración tecnológica	Media-baja a corto plazo	Alto potencial de reducción de tráfico, pero requiere diseño institucional y tecnológico complejo	No estimado en este trabajo; podría generar beneficios relevantes si reduce de forma estable el tráfico

* **Nota metodológica:** las cifras de muertes potencialmente evitables no son predicciones exactas ni deben sumarse entre sí. Son aproximaciones ilustrativas obtenidas al aplicar los porcentajes estimados de reducción de PM2.5 a una referencia de **56.443 muertes prematuras atribuibles a PM2.5 en Beijing**. Su valor principal es mostrar el **orden de magnitud** del beneficio sanitario potencial

Referencias orientativas para la estimación de costes

La clasificación de costes incluida en la tabla se ha elaborado por **orden de magnitud** y con un criterio comparativo entre tipos de medidas, no como un presupuesto cerrado para Beijing. Para justificar esta escala, se han tomado como referencia varios casos y fuentes externas.

En el caso de las **herramientas digitales y de alerta**, el coste se ha considerado **bajo** en comparación con las intervenciones estructurales sobre movilidad. Como referencia, el Gobierno de Gujarat anunció en 2026 una plataforma digital integrada de monitorización de calidad del aire y del agua con un presupuesto estimado de **₹10 crore**, lo que muestra que una solución tecnológica de este tipo puede implantarse con un coste relativamente contenido en comparación con grandes infraestructuras urbanas.
https://timesofindia.indiatimes.com/city/ahmedabad/gujarat-plans-rs-10cr-digital-platform-to-monitor-lakes-and-aqi/articleshow/129414982.cms?utm_source

Las medidas de **teletrabajo parcial, horarios escalonados y gestión de la demanda** se han clasificado como de **coste bajo-medio o medio**, ya que no requieren una gran infraestructura física, pero sí incentivos, coordinación institucional, seguimiento y

comunicación con empresas y ciudadanía. Además, la evidencia reciente sugiere que el teletrabajo puede reducir emisiones del transporte al disminuir los desplazamientos pendulares, lo que respalda su inclusión como medida de fomento complementaria.

https://www.sciencedirect.com/science/article/pii/S2590198225001010?utm_source

Por su parte, las medidas de **restricción horaria del tráfico**, los **protocolos de activación por meteorología** y el **refuerzo del transporte público en episodios críticos** se han considerado de **coste medio**, porque exigen señalización, fiscalización, personal operativo, campañas de información y una capacidad adicional de gestión del sistema de transporte, aunque no necesariamente grandes inversiones permanentes en infraestructura. Esta valoración se apoya en recomendaciones internacionales que subrayan la importancia de combinar monitorización, gestión de datos, comunicación del riesgo y capacidad de respuesta institucional en las políticas de calidad del aire.

https://web.stanford.edu/~ost/papers/nyc.pdf?utm_source

Finalmente, los sistemas de **peaje urbano o control de acceso estructural** se han clasificado como de **coste alto**, dado que requieren infraestructura tecnológica compleja, cámaras, sensores, sistemas de cobro, integración operativa y largos periodos de preparación institucional. Como ejemplo, el programa de congestion pricing de Nueva York ha supuesto **cientos de millones de dólares** en infraestructura de soporte y está vinculado a inversiones de capital mucho más amplias en transporte público.

https://www.who.int/news-room/fact-sheets/detail/ambient-%28outdoor%29-air-quality-and-health?utm_source=chatgpt.com

En consecuencia, los costes presentados en este trabajo deben entenderse como una **estimación comparativa y estratégica**, útil para priorizar políticas públicas, pero no como una valoración económica definitiva para la ciudad de Beijing.

Priorización recomendada

A la luz de los resultados, la estrategia más razonable para el Ayuntamiento de Beijing sería combinar medidas de **rápida implantación y coste moderado** con medidas de mayor alcance aplicadas de forma piloto. En este sentido, las prioridades deberían ser las siguientes:

1. **Protocolo de baja dispersión atmosférica**, por su buena relación entre impacto esperado, coste y aceptabilidad.
2. **Priorización por franjas horarias**, especialmente entre **18:00–20:00** o **7:00–9:00**, según el criterio de evaluación.
3. **Teletrabajo parcial, horarios escalonados y app municipal de alertas**, como medidas no restrictivas de apoyo.
4. **Restricción progresiva del tráfico**, comenzando por escenarios moderados antes de ampliar la intensidad de la intervención.
5. **Peaje urbano o control de acceso estructural**, únicamente como fase posterior, dado su mayor coste y complejidad de implantación.

En consecuencia, la recomendación general no es aplicar una prohibición indiscriminada del tráfico, sino construir una política pública escalonada, inteligente y evaluable, capaz de reducir tanto las emisiones como la exposición de la población en los momentos de mayor riesgo.